



یادگیری ماشین

پاییز و زمستان ۱۴۰۴

استاد: علی شریفی زارچی

گردآورندگان: حسن بیگی - رحمانی - غریبی - هدایی - یوسف نیا

تمرین دوم

یادگیری بدون نظارت

مهلت ارسال: ۱۴ آذر

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- در طول ترم، برای هر تمرین می‌توانید تا ۵ روز تأخیر مجاز داشته باشید و در مجموع حداکثر ۱۵ روز تأخیر مجاز خواهید داشت. توجه داشته باشید که تأخیر در تمرین‌های عملی و تئوری به صورت جداگانه محاسبه می‌شود و مجموع تأخیر هر دو نباید بیشتر از ۱۵ روز شود. پس از اتمام زمان مجاز، دو روز اضافی برای آپلود غیرمجاز در نظر گرفته شده است که در این بازه، به ازای هر ساعت تأخیر، ۲ درصد از نمره تمرین کسر خواهد شد.
- همکاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ‌های هر کس حتماً باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفاً تصویری واضح از پاسخ‌های سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.

سوالات نظری (۱۰۰ نمره)

۱. (۱۵ نمره) در هر مورد انتخاب خود را همراه با استدلال مختصر بیان کنید.
 - کدام یک از موارد زیر مزایای معمولی هستند که ممکن است شما را ترغیب کند تا قبل از آموزش یک طبقه‌بندی‌کننده Classifier، داده‌ها را با PCA پیش‌پردازش کنید؟ (گزینه‌های صحیح را انتخاب کنید)
 - (آ) PCA تمایل دارد بایاس الگوریتم طبقه‌بندی شما را کاهش دهد.
 - (ب) از PCA می‌توان برای جلوگیری از بیش‌برازش (Overfitting) استفاده کرد.
 - (ج) PCA تمایل دارد واریانس الگوریتم طبقه‌بندی شما را کاهش دهد.
 - (د) از PCA می‌توان برای جلوگیری از کم‌برازش (Underfitting) استفاده کرد.
 - گزاره‌های صحیح در مورد تحلیل مؤلفه‌های اصلی PCA را انتخاب کنید.
 - (آ) PCA یک الگوریتم خوشه‌بندی است.
 - (ب) PCA ویژگی‌هایی تولید می‌کند که ترکیبات خطی از ویژگی‌های ورودی هستند.
 - (ج) مؤلفه‌های اصلی طوری انتخاب می‌شوند که واریانس داده‌ها را به حداکثر برسانند.
 - (د) مختصات اصلی همان مقادیر ویژه ماتریس کوواریانس نمونه هستند.
 - گزاره‌های صحیح درباره خوشه‌بندی k -means را انتخاب کنید.
 - (آ) k -means تضمین می‌کند که خوشه‌هایی را پیدا کند که تابع هزینه را کمینه کنند.
 - (ب) در خروجی، هر دو خوشه توسط یک مرکز تصمیم خطی جدا شده‌اند.
 - (ج) امکان کرنلایز کردن k -means وجود ندارد.
 - (د) از دید آماری بهینه‌سازی k -means را با فرض پیشین‌گوسی روی میانگین‌ها و با استفاده از تخمین حداکثر درست‌نمایی توجیه می‌کنند.
 - گزاره‌های صحیح درباره زمان اجرای الگوریتم k -means برای n نقطه با d ویژگی را انتخاب کنید.

- (آ) مرحله به‌روزرسانی میانگین خوشه‌ها می‌تواند در زمان $O(nd)$ اجرا شود.
- (ب) افزایش k همیشه زمان اجرا را افزایش می‌دهد.
- (ج) مرحله تخصیص خوشه‌ها می‌تواند در زمان $O(nkd)$ اجرا شود.
- (د) الگوریتم k -means حداکثر در زمان $O(nkd)$ اجرا می‌شود.

حل.

- (آ) **نادرست.** زیرا PCA با حذف برخی از مؤلفه‌ها (اطلاعات)، مدل را ساده‌تر می‌کند. ساده‌سازی مدل معمولاً منجر به افزایش بایاس می‌شود، نه کاهش آن.
- (ب) **درست.** زیرا PCA ابعاد و نویز داده‌ها را کاهش می‌دهد. کاهش پیچیدگی مدل، واریانس آن را کم کرده و در نتیجه به جلوگیری از بیش‌برازش (Overfitting) کمک می‌کند.
- (ج) **درست.** زیرا همان‌طور که در گزینه (ب) ذکر شد، کاهش ابعاد باعث می‌شود مدل به نویزهای خاص مجموعه آموزش کمتر حساس باشد و در نتیجه واریانس آن کاهش می‌یابد.
- (د) **نادرست.** زیرا PCA با حذف اطلاعات، ظرفیت مدل را کاهش می‌دهد. این امر ممکن است احتمال کم‌برازش (Underfitting) را افزایش دهد، نه اینکه از آن جلوگیری کند.
- (آ) **نادرست.** زیرا PCA یک الگوریتم کاهش ابعاد (Dimensionality Reduction) بدون نظارت است، نه یک الگوریتم خوشه‌بندی.
- (ب) **درست.** زیرا هر مؤلفه اصلی (PC) حاصل ضرب داخلی بردار ویژگی‌های ورودی در بردار وزن‌هاست که یک ترکیب خطی محسوب می‌شود.
- (ج) **درست.** زیرا هدف اصلی PCA یافتن جهت‌هایی متعامد است که داده‌ها در آن جهت‌ها بیشترین پراکندگی (واریانس) را داشته باشند.
- (د) **نادرست.** زیرا مقادیر ویژه (Eigenvalues) بیانگر میزان واریانس داده‌ها در جهت مؤلفه‌های اصلی هستند، نه خود مختصات یا داده‌های تصویر شده.
- (آ) **نادرست.** زیرا تابع هزینه k -means غیرمحدب (Non-convex) است و الگوریتم تنها تضمین می‌کند که به یک بهینه محلی (Local Optimum) همگرا شود، نه لزوماً بهینه سراسری.
- (ب) **درست.** زیرا ناحیه مربوط به هر خوشه، مجموعه‌ی نقاطی است که به مرکز آن خوشه نزدیک‌ترند (سلول‌های ورونوی). مرز بین دو مرکز، عمودمنصف پاره‌خط واصل آن‌هاست که یک مرز خطی (یا ابرصفحه) است.
- (ج) **نادرست.** زیرا نسخه‌های کرنل‌دار این الگوریتم (Kernel k -means) وجود دارند که می‌توانند خوشه‌هایی با مرزهای غیرخطی را جدا کنند. در واقع چون می‌توان این الگوریتم را کاملاً بر حسب ضرب داخلی داده‌ها بیان کرد، می‌توان آن را کرنلایز هم کرد.
- (د) **نادرست.** زیرا توجیه آماری رایج برای k -means، تخمین حداکثر درست‌نمایی (MLE) روی مدل مخلوط گوسی (GMM) با کوواریانس‌های کروی و یکسان است، نه استفاده از فرض پیشین (Prior) روی میانگین‌ها (که رویکرد بیزی محسوب می‌شود).
- (آ) **درست.** زیرا برای به‌روزرسانی میانگین‌ها، باید مختصات تمام n نقطه را جمع کرده و بر تعداد تقسیم کنیم که متناسب با تعداد کل درایه‌ها یعنی $O(nd)$ است.
- (ب) **نادرست.** زیرا اگرچه پیچیدگی هر تکرار افزایش می‌یابد، اما تغییر k ممکن است تعداد تکرارهای لازم برای همگرایی را تغییر دهد و نمی‌توان گفت همیشه کل زمان اجرا افزایش می‌یابد. (اما پیچیدگی هر گام زیاد می‌شود).
- (ج) **درست.** زیرا در مرحله تخصیص، باید فاصله هر یک از n نقطه را با هر یک از k مرکز (که هر کدام d بعد دارند) محاسبه کنیم.
- (د) **نادرست.** زیرا $O(nkd)$ تنها هزینه یک تکرار (Iteration) است. زمان کل برابر است با حاصل ضرب تعداد تکرارها (T) در هزینه هر تکرار: $O(T \cdot nkd)$.

۲. (۲۰ نمره) به سؤالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(آ) ثابت کنید الگوریتم k -means همگرا می‌شود.

(ب) با یک مثال عددی نشان دهید که الگوریتم k -means نسبت به داده‌های outlier مقاوم نیست. سپس با ارائه یک اصلاح ad-hoc سعی کنید مقاومت این روش را در شرایط حضور outlierها بهبود دهید. در رابطه با مزایا و معایب این تغییر بحث کنید.

(ج) الگوریتم‌های k -means و DBSCAN را از حیث مقاومت نسبت به داده‌های outlier مقایسه کنید.
حل.

(آ) برای اثبات همگرایی، باید نشان دهیم که تابع هدف (تابع هزینه) الگوریتم در هر تکرار غیرصعودی است و از پایین کران‌دار است.
تابع هدف در الگوریتم k -means مجموع مربعات خطای درون خوشه‌ای (WCSS) است:

$$J = \sum_{j=1}^k \sum_{x_i \in S_j} \|x_i - \mu_j\|^2$$

که در آن S_j مجموعه نقاط متعلق به خوشه j و μ_j میانگین آن خوشه است. الگوریتم شامل دو مرحله تکرارشونده است:

۱. **مرحله تخصیص (Assignment Step):** در این مرحله، مراکز μ_j ثابت فرض می‌شوند. هر نقطه x_i به خوشه‌ای اختصاص می‌یابد که کمترین فاصله اقلیدسی را با مرکز آن دارد.

$$S_j^{(t)} = \{x_i : \|x_i - \mu_j^{(t)}\|^2 \leq \|x_i - \mu_l^{(t)}\|^2 \quad \forall l \neq j\}$$

از آنجا که هر نقطه به نزدیک‌ترین مرکز اختصاص می‌یابد، مقدار هر عبارت $\|x_i - \mu\|$ در مجموع J کاهش می‌یابد یا ثابت می‌ماند. بنابراین J در این مرحله کاهش می‌یابد.

۲. **مرحله به‌روزرسانی (Update Step):** در این مرحله، تخصیص نقاط S_j ثابت است و مراکز μ_j به‌روز می‌شوند. هدف یافتن بردار μ_j است که مجموع مربعات خطا را برای خوشه j کمینه کند:

$$J_j(\mu_j) = \sum_{x \in S_j} \|x - \mu_j\|^2$$

برای یافتن مقدار بهینه، از J_j نسبت به بردار μ_j گرادیان گرفته و برابر صفر قرار می‌دهیم:

$$\begin{aligned} \nabla_{\mu_j} J_j &= \nabla_{\mu_j} \sum_{x \in S_j} (x - \mu_j)^\top (x - \mu_j) \\ &= \sum_{x \in S_j} \nabla_{\mu_j} ((x - \mu_j)^\top (x - \mu_j)) \\ &= \sum_{x \in S_j} -2(x - \mu_j) \end{aligned}$$

حال گرادیان را برابر صفر قرار می‌دهیم:

$$\begin{aligned} -2 \sum_{x \in S_j} (x - \mu_j) &= 0 \\ \sum_{x \in S_j} x - \sum_{x \in S_j} \mu_j &= 0 \end{aligned}$$

از آنجا که μ_j نسبت به اندیس سیگما ثابت است و تعداد اعضای مجموعه S_j برابر با $|S_j|$ می باشد، داریم:

$$\sum_{x \in S_j} x - |S_j| \mu_j = 0$$

$$|S_j| \mu_j = \sum_{x \in S_j} x$$

$$\mu_j^{(t+1)} = \frac{1}{|S_j|} \sum_{x \in S_j} x$$

چون مشتق دوم (هسین) این تابع برابر با $2|S_j|I$ (ماتریس قطری مثبت) است، این نقطه قطعاً یک کمینه سراسری برای آن گام است. بنابراین، به روزرسانی μ_j به میانگین حسابی، مقدار J را کاهش می دهد یا ثابت نگه می دارد.

در نتیجه از آنجا که تابع هزینه J همواره مثبت است (کران پایین صفر دارد) و در هر دو مرحله الگوریتم مقدار آن غیرصعودی است، الگوریتم به سمت یک مقدار همگرا می شود. همچنین چون تعداد حالات افراز نقاط به k خوشه محدود است (حداکثر k^n که n تعداد داده ها است)، الگوریتم نمی تواند تا بی نهایت ادامه یابد و در نهایت همگرا می شود (معمولاً به یک بهینه محلی).

(ب) فرض کنید مجموعه ای از نقاط یک بعدی داریم: $D = \{2, 3, 4, 100\}$. می خواهیم این داده ها را با $k = 1$ خوشه بندی کنیم.

• **عملکرد k -means:** مرکز خوشه (میانگین) برابر است با:

$$\mu = \frac{2 + 3 + 4 + 100}{4} = \frac{109}{4} = 27.25$$

همان طور که مشاهده می شود، وجود داده پرت (Outlier) یعنی 100، باعث شده مرکز خوشه از ناحیه پرتراکم داده ها (2, 3, 4) فاصله زیادی بگیرد و نماینده خوبی برای آن ها نباشد.

• **اصلاح پیشنهادی (k -medians):** به عنوان یک راهکار، می توان به جای استفاده از میانگین (Mean)، از میانه (Median) برای محاسبه مرکز خوشه استفاده کرد (استفاده از نرم L_1 به جای L_2).

در این مثال، میانه داده های $\{2, 3, 4, 100\}$ برابر است با میانگین دو عدد وسط (یا یکی از اعداد وسط در حالت فرد):

$$\text{Median} = \frac{3 + 4}{2} = 3.5$$

عدد 3/5 بسیار نزدیک به داده های اصلی است و تحت تأثیر عدد 100 قرار نگرفته است.

مزایا و معایب k -medians:

- **مزایا:** مقاومت بسیار بالا در برابر داده های پرت (Robustness).
- **معایب:** هزینه محاسباتی بالاتر؛ محاسبه میانگین در زمان خطی انجام می شود، اما محاسبه میانه (مخصوصاً در ابعاد بالا تحت عنوان Geometric Median) پیچیدگی محاسباتی بیشتری دارد.

(ج) • **الگوریتم k -means:** این الگوریتم تمام نقاط داده، حتی نقاط پرت را مجبور می کند که عضوی از خوشه ها باشند. از آنجا که تابع هزینه مبتنی بر میانگین گیری است، نقاط پرت وزن زیادی در تعیین موقعیت مراکز دارند و می توانند مرزهای تصمیم گیری و مکان مراکز را به شدت تغییر دهند. بنابراین این الگوریتم نسبت به Outlier حساس است.

• **الگوریتم DBSCAN:** این الگوریتم مبتنی بر چگالی است و دارای مفهوم صریحی برای نویز (Noise) می‌باشد. نقاطی که در نواحی کم‌چگالی قرار دارند و به تعداد حداقل همسایه (MinPts) نمی‌رسند، به عنوان هیچ خوشه‌ای طبقه‌بندی نشده و برچسب ۱- یا نویز می‌گیرند. این نقاط در محاسبه خوشه‌های اصلی مشارکت داده نمی‌شوند. بنابراین DBSCAN نسبت به داده‌های پرت مقاوم است.

۳. (۱۵ نمره) مجموعه نمونه زیر از شش نقطه $X_i \in \mathbb{R}^2$ را در نظر بگیرید:

$$\left\{ \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 2 \end{pmatrix} \right\}$$

- (آ) میانگین نقاط نمونه را محاسبه کرده و ماتریس طرح متمرکز (Centered Design Matrix) را بنویسید.
 (ب) تمام مؤلفه‌های اصلی را بیابید و آن‌ها را به صورت بردار واحد بنویسید.
 (ج) اگر فقط از یک مؤلفه استفاده کنیم، کدام ترجیح دارد؟ الگوریتم PCA از چه اطلاعاتی برای ترجیح یکی بر دیگری استفاده می‌کند؟ از منظر بهینه‌سازی، چرا آن یکی را ترجیح می‌دهیم؟
 (د) بردار تصویر هر یک از نقاط (نه نقاط متمرکز شده) را بر روی مؤلفه اصلی ترجیحی محاسبه کنید.

حل.

(آ) ابتدا میانگین برداری داده‌ها ($\bar{x}$) را محاسبه می‌کنیم. تعداد نقاط $N = 6$ است.

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{6} \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} 2 \\ 1 \end{pmatrix} + \begin{pmatrix} 2 \\ 2 \end{pmatrix} \right]$$

$$\bar{x} = \frac{1}{6} \begin{pmatrix} 6 \\ 6 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

حال برای به دست آوردن ماتریس طرح متمرکز (X_c)، میانگین را از تک‌تک داده‌ها کم می‌کنیم ($\tilde{x}_i = x_i - \bar{x}$):

$$\begin{aligned} \tilde{x}_1 &= (0, 0)^T - (1, 1)^T = (-1, -1)^T \\ \tilde{x}_2 &= (0, 1)^T - (1, 1)^T = (-1, 0)^T \\ \tilde{x}_3 &= (1, 0)^T - (1, 1)^T = (0, -1)^T \\ \tilde{x}_4 &= (1, 1)^T - (1, 1)^T = (0, 0)^T \\ \tilde{x}_5 &= (2, 1)^T - (1, 1)^T = (1, 0)^T \\ \tilde{x}_6 &= (2, 2)^T - (1, 1)^T = (1, 1)^T \end{aligned}$$

ماتریس طرح متمرکز (که در آن هر سطر یک نمونه است):

$$X_c = \begin{pmatrix} -1 & -1 \\ -1 & 0 \\ 0 & -1 \\ 0 & 0 \\ 1 & 0 \\ 1 & 1 \end{pmatrix}$$

(ب) برای یافتن مؤلفه‌های اصلی، ابتدا ماتریس کوواریانس (یا ماتریس پراکندگی $S = \mathbf{X}_c^T \mathbf{X}_c$) را تشکیل می‌دهیم:

$$\mathbf{X}_c^T \mathbf{X}_c = \begin{pmatrix} -1 & -1 & 0 & 0 & 1 & 1 \\ -1 & 0 & -1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} -1 & -1 \\ -1 & 0 \\ 0 & -1 \\ 0 & 1 \\ 1 & 0 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}$$

برای یافتن مقادیر ویژه (λ) و بردارهای ویژه $(\mathbf{v})$ ، معادله مشخصه $\det(\mathbf{S} - \lambda \mathbf{I}) = 0$ را حل می‌کنیم:

$$\det \begin{pmatrix} 4 - \lambda & 2 \\ 2 & 4 - \lambda \end{pmatrix} = (4 - \lambda)^2 - 4 = 0$$

$$(4 - \lambda) = \pm 2 \implies \lambda_1 = 6, \quad \lambda_2 = 2$$

حال بردارهای ویژه متناظر را می‌یابیم:

برای $\lambda_1 = 6$:

$$\begin{pmatrix} 4 - 6 & 2 \\ 2 & 4 - 6 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} -2 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = 0 \implies v_1 = v_2$$

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{ بردار واحد نرمال شده:}$$

برای $\lambda_2 = 2$:

$$\begin{pmatrix} 4 - 2 & 2 \\ 2 & 4 - 2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = 0 \implies v_1 = -v_2$$

$$\mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix} \text{ بردار واحد نرمال شده:}$$

بنابراین مؤلفه‌های اصلی عبارتند از $\mathbf{u}_1$ و $\mathbf{u}_2$.

(ج) • کدام ترجیح دارد؟ مؤلفه اول یعنی $\mathbf{u}_1 = \frac{1}{\sqrt{2}}(1, 1)^T$ ترجیح داده می‌شود.

• الگوریتم PCA از چه اطلاعاتی استفاده می‌کند؟ الگوریتم از مقادیر ویژه (λ) استفاده می‌کند.

مقدار ویژه متناظر با هر مؤلفه، نشان‌دهنده میزان واریانس داده‌ها در جهت آن مؤلفه است. چون $\lambda_1 = 6 > \lambda_2 = 2$ ، جهت $\mathbf{u}_1$ اطلاعات (پراکندگی) بیشتری از داده‌ها را در خود دارد.

• چرا از منظر بهینه‌سازی مؤلفه اول ترجیح داده می‌شود؟ هدف PCA کمینه کردن مجموع

مربعات خطای بازسازی (Reconstruction Error) است. از نظر ریاضی ثابت می‌شود که جهت

دارای بیشترین واریانس (بزرگترین مقدار ویژه)، جهتی است که اگر داده‌ها را روی آن تصویر کنیم،

کمترین فاصله را با داده‌های اصلی خواهند داشت (کمترین خطا).

(د) در اینجا تصویر هر یک از نقاط خام $\mathbf{x}_i$ (بدون کسر میانگین) را بر روی جهت مؤلفه اصلی $\mathbf{u}_1$

$$\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{ محاسبه می‌کنیم. حاصل یک عدد اسکالر خواهد بود:}$$

$$y_i = \mathbf{x}_i^T \mathbf{u}_1 = x_{i1} \cdot \frac{1}{\sqrt{2}} + x_{i2} \cdot \frac{1}{\sqrt{2}} = \frac{x_{i1} + x_{i2}}{\sqrt{2}}$$

• نقطه ۱: $\mathbf{x}_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$$y_1 = \frac{0 + 1}{\sqrt{2}} = \frac{1}{\sqrt{2}}$$

• نقطه ۲ $x_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$:

$$y_2 = \frac{0+1}{\sqrt{2}} = \frac{1}{\sqrt{2}} \approx 0.707$$

• نقطه ۳ $x_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$:

$$y_3 = \frac{1+1}{\sqrt{2}} = \frac{2}{\sqrt{2}} \approx 1.414$$

• نقطه ۴ $x_4 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$:

$$y_4 = \frac{1+2}{\sqrt{2}} = \frac{3}{\sqrt{2}} \approx 2.121$$

• نقطه ۵ $x_5 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$:

$$y_5 = \frac{2+1}{\sqrt{2}} = \frac{3}{\sqrt{2}} \approx 2.121$$

• نقطه ۶ $x_6 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$:

$$y_6 = \frac{2+2}{\sqrt{2}} = \frac{4}{\sqrt{2}} = 2\sqrt{2} \approx 2.828$$

۴. (۲۰ نمره) به سؤالاتی که در ادامه آمده‌اند با بیان توضیحات کامل پاسخ دهید.

(آ) در دسته‌ای از مسائل تخمین پارامتر، با مدل‌هایی رو به رو هستیم که خروجی‌های آن، علاوه بر مجموعه‌ای از نمونه‌های مشاهده‌شده (X) ، شامل مجموعه‌ای از اطلاعات نهان (Z) نیز می‌باشد. حضور پارامتر جدید Z به عنوان یک مجهول، باعث می‌شود تکنیک‌هایی نظیر MLE در این مسائل قابل استفاده نباشد. الگوریتم EM برای پاسخ به این چالش، مسئله را به دو مرحله تقسیم می‌کند. در هر گام t :

۱. ابتدا پارامترهای توزیع $\theta^{(t)}$ ثابت در نظر گرفته می‌شود و امید ریاضی تابع $\log \text{likelihood}$ نسبت به توزیع شرطی $\mathbb{P}(Z | X, \theta^{(t)})$ به دست می‌آید.

۲. سپس همانند روش‌های پیشین تخمین پارامتر، پارامترهایی که مقدار به دست آمده را بیشینه کنند، به عنوان پارامترهای جدید انتخاب می‌شوند.

یکی از مهم‌ترین کاربردهای این مدل‌سازی، تخمین پارامترهای توزیع‌های مخلوط است؛ به این صورت که تعلق نمونه‌ها به هر مؤلفه توسط پارامتر نهان Z مدل‌سازی می‌شود. توزیع مخلوط زیر را در نظر بگیرید:

$$\mathbb{P}(X) = \alpha \lambda_1 e^{-\lambda_1 X} + (1 - \alpha) \lambda_2 e^{-\lambda_2 X}$$

فرض کنید نمونه‌های $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} \mathbb{P}(X)$ را در اختیار داریم و می‌خواهیم با EM پارامترهای $\alpha, \lambda_1, \lambda_2$ را تخمین بزنیم. اگر متغیر نهان Z_i به صورت زیر تعریف شود:

$$Z_i = \begin{cases} 0 & X_i \text{ comes from the first component of } \mathbb{P}(X) \\ 1 & X_i \text{ comes from the second component of } \mathbb{P}(X) \end{cases}$$

تابع $\log \text{likelihood}$ complete-data که به شکل $\log \mathbb{P}(X_1, Z_1, \dots, X_n, Z_n | \lambda_1, \lambda_2, \alpha)$ تعریف می‌شود را بیابید.

(ب) امید ریاضی تابع complete-data log likelihood را نسبت به متغیرهای نهان محاسبه کنید (در محاسبات خود به مقدار $\mathbb{E}[Z_i | X_i, \alpha^{(t)}, \lambda_1^{(t)}, \lambda_2^{(t)}]$ نیاز خواهید داشت و باید آن را محاسبه کنید)

(ج) روابط به‌روزرسانی پارامترهای α و λ_1 را استخراج کنید. (برای سادگی، مقدار مرحله قبل را $\gamma_i^{(t)}$ بنامید.)

حل.

(آ) برای محاسبه این تابع، ابتدا باید تابع چگالی احتمال مشترک یک نمونه (X_i, Z_i) را بنویسیم. طبق تعریف مسئله:

- اگر $Z_i = 0$ باشد (با احتمال α)، آنگاه X_i از توزیع نمایی با پارامتر λ_1 می‌آید:

$$\mathbb{P}(X_i | Z_i = 0) = \lambda_1 e^{-\lambda_1 X_i}$$

- اگر $Z_i = 1$ باشد (با احتمال $1 - \alpha$)، آنگاه X_i از توزیع نمایی با پارامتر λ_2 می‌آید:

$$\mathbb{P}(X_i | Z_i = 1) = \lambda_2 e^{-\lambda_2 X_i}$$

می‌توانیم تابع احتمال مشترک را به کمک توان‌رسانی (روشی رایج برای متغیرهای باینری) به صورت فشرده بنویسیم. توجه کنید که چون $Z_i \in \{0, 1\}$ ، عبارت $(1 - Z_i)$ نشان‌گر تعلق به مؤلفه اول و Z_i نشان‌گر تعلق به مؤلفه دوم است:

$$\mathbb{P}(X_i, Z_i | \Theta) = [\alpha \lambda_1 e^{-\lambda_1 X_i}]^{(1-Z_i)} \times [(1 - \alpha) \lambda_2 e^{-\lambda_2 X_i}]^{Z_i}$$

تابع درست‌نمایی کل برای n نمونه مستقل برابر است با حاصل ضرب احتمالات مشترک تک‌تک نمونه‌ها:

$$L(\Theta) = \prod_{i=1}^n \left([\alpha \lambda_1 e^{-\lambda_1 X_i}]^{(1-Z_i)} [(1 - \alpha) \lambda_2 e^{-\lambda_2 X_i}]^{Z_i} \right)$$

با گرفتن لگاریتم طبیعی، تابع complete-data log likelihood به دست می‌آید:

$$\begin{aligned} \mathcal{L}_c(\Theta) &= \log L(\Theta) = \sum_{i=1}^n \left[(1 - Z_i) \log(\alpha \lambda_1 e^{-\lambda_1 X_i}) + Z_i \log((1 - \alpha) \lambda_2 e^{-\lambda_2 X_i}) \right] \\ &= \sum_{i=1}^n \left[(1 - Z_i) (\log \alpha + \log \lambda_1 - \lambda_1 X_i) + Z_i (\log(1 - \alpha) + \log \lambda_2 - \lambda_2 X_i) \right] \end{aligned}$$

(ب) در گام E، هدف محاسبه امید ریاضی متغیرهای نهان Z_i به شرط داده‌های مشاهده شده X_i و پارامترهای گام فعلی $\Theta^{(t)}$ است. از آنجا که Z_i یک متغیر تصادفی برنولی است (مقدار 0 یا 1 می‌گیرد)، امید ریاضی آن برابر است با احتمال اینکه $Z_i = 1$ باشد (یعنی احتمال اینکه داده از مؤلفه دوم آمده باشد):

$$\gamma_i^{(t)} \triangleq \mathbb{E}[Z_i | X_i, \Theta^{(t)}] = P(Z_i = 1 | X_i, \Theta^{(t)}) \times 1 + P(Z_i = 0 | X_i, \Theta^{(t)}) \times 0$$

با استفاده از قانون بیز (Bayes' Rule) داریم:

$$P(Z_i = 1 | X_i, \Theta^{(t)}) = \frac{P(X_i | Z_i = 1, \Theta^{(t)}) P(Z_i = 1 | \Theta^{(t)})}{P(X_i | \Theta^{(t)})}$$

مخرج کسر طبق قانون احتمال کل برابر است با مجموع احتمالات دو مؤلفه. با جایگذاری مقادیر توزیع نمایی و ضرایب مخلوط:

$$\gamma_i^{(t)} = \frac{(1 - \alpha^{(t)})\lambda_2^{(t)} e^{-\lambda_2^{(t)} X_i}}{\alpha^{(t)}\lambda_1^{(t)} e^{-\lambda_1^{(t)} X_i} + (1 - \alpha^{(t)})\lambda_2^{(t)} e^{-\lambda_2^{(t)} X_i}}$$

این مقدار $\gamma_i^{(t)}$ همان «مسئولیت» (Responsibility) مؤلفه دوم برای داده i ام است. (بدیهی است که امید ریاضی برای مؤلفه اول برابر با $1 - \gamma_i^{(t)}$ خواهد بود). بنابراین امید ریاضی تابع درست‌نمایی (تابع Q) برابر می‌شود با:

$$Q(\Theta, \Theta^{(t)}) = \sum_{i=1}^n \left[(1 - \gamma_i^{(t)}) (\log \alpha + \log \lambda_1 - \lambda_1 X_i) + \gamma_i^{(t)} (\log(1 - \alpha) + \log \lambda_2 - \lambda_2 X_i) \right]$$

(ج) برای یافتن مقادیر بهینه، باید از تابع Q نسبت به پارامترها مشتق گرفته و برابر صفر قرار دهیم.
۱. به‌روزرسانی α : تنها جملات شامل α را در نظر می‌گیریم:

$$J(\alpha) = \sum_{i=1}^n \left[(1 - \gamma_i^{(t)}) \log \alpha + \gamma_i^{(t)} \log(1 - \alpha) \right]$$

مشتق نسبت به α :

$$\frac{\partial J}{\partial \alpha} = \sum_{i=1}^n \left[\frac{1 - \gamma_i^{(t)}}{\alpha} - \frac{\gamma_i^{(t)}}{1 - \alpha} \right] = 0$$

$$\frac{1}{\alpha} \sum_{i=1}^n (1 - \gamma_i^{(t)}) = \frac{1}{1 - \alpha} \sum_{i=1}^n \gamma_i^{(t)}$$

اگر قرار دهیم $N_2 = \sum \gamma_i^{(t)}$ (تعداد مؤثر نمونه‌های کلاس ۲) و $N_1 = \sum (1 - \gamma_i^{(t)}) = n - N_2$ (تعداد مؤثر نمونه‌های کلاس ۱):

$$\frac{N_1}{\alpha} = \frac{N_2}{1 - \alpha} \implies N_1(1 - \alpha) = N_2\alpha \implies N_1 = \alpha(N_1 + N_2) \implies N_1 = \alpha n$$

$$\alpha^{(t+1)} = \frac{N_1}{n} = \frac{\sum_{i=1}^n (1 - \gamma_i^{(t)})}{n}$$

۲. به‌روزرسانی λ_1 : تنها جملات شامل λ_1 را در نظر می‌گیریم (مربوط به مؤلفه اول):

$$J(\lambda_1) = \sum_{i=1}^n (1 - \gamma_i^{(t)}) (\log \lambda_1 - \lambda_1 X_i)$$

مشتق نسبت به λ_1 :

$$\frac{\partial J}{\partial \lambda_1} = \sum_{i=1}^n (1 - \gamma_i^{(t)}) \left(\frac{1}{\lambda_1} - X_i \right) = 0$$

$$\frac{1}{\lambda_1} \sum_{i=1}^n (1 - \gamma_i^{(t)}) = \sum_{i=1}^n (1 - \gamma_i^{(t)}) X_i$$


$$\lambda_1^{(t+1)} = \frac{\sum_{i=1}^n (1 - \gamma_i^{(t)})}{\sum_{i=1}^n (1 - \gamma_i^{(t)}) X_i}$$

توضیح شهودی: این فرمول مشابه برآورد MLE توزیع نمایی استاندارد ($1/\bar{X}$) است، با این تفاوت که میانگین وزنی نمونه‌ها (با وزن تعلق به کلاس اول) محاسبه شده است.

۵. (۱۵ نمره) برای هر یک از خوشه‌بندی‌های ارائه‌شده روی نقاط دوبعدی (هر کدام با $k = 2$ خوشه) که در آن نقاط قرمز مربوط به خوشه اول و نقاط آبی مربوط به خوشه دوم هستند، مشخص کنید کدام یک از الگوریتم‌های زیر می‌توانستند منجر به این تخصیص خوشه‌ای شده باشند:

- (آ) الگوریتم k -means
 (ب) خوشه‌بندی single-link
 (ج) مدل‌های مخلوط گاوسی (GMM) Gaussian Mixture Models
 (د) هیچ‌یک از موارد فوق

ممکن است بیش از یک پاسخ صحیح باشد؛ تمام گزینه‌هایی را که ممکن است منجر به این خوشه‌بندی شده باشند با بیان استدلال ذکر کنید.



حل.

تصویر A: پاسخ‌های ممکن: (آ)، (ب) و (ج)

- (آ) k -means: داده‌ها به صورت دو ابر کروی جدا از هم هستند. k -means با یک مرز خطی عمودمنصف خط واصل میانگین‌ها) به راحتی این دو را جدا می‌کند.
- (ب) Single-link: فاصله بین دو گروه داده بسیار بیشتر از فاصله بین نقاط درون هر گروه است، بنابراین این روش به درستی عمل می‌کند.
- (ج) GMM: داده‌ها را می‌توان با دو توزیع گاوسی کروی مدل کرد، پس GMM نیز موفق است.

تصویر B: پاسخ‌های ممکن: (ج)

- (ج) GMM: خوشه قرمز بسیار متراکم (واریانس کم) و خوشه آبی بسیار پراکنده (واریانس زیاد) است. GMM تنها مدلی است که می‌تواند خوشه‌هایی با اندازه‌ها و واریانس‌های متفاوت را مدیریت کند.
- چرا بقیه نه؟ الگوریتم k -means تمایل دارد خوشه‌هایی با اندازه (شعاع) برابر ایجاد کند و احتمالاً بخشی از نقاط دورتر آبی را به قرمز اختصاص می‌داد. Single-link نیز به دلیل وجود نقاط آبی که به خوشه قرمز نزدیک‌ترند تا به سایر نقاط آبی (مشکل chaining یا نویز)، احتمالاً آن نقاط را به قرمز وصل می‌کرد.

تصویر C: پاسخ‌های ممکن: (ب) و (ج)

- (ب) Single-link: داده‌ها دارای پیوستگی هستند و فاصله بین دو نوار موازی بیشتر از فاصله نقاط داخلی است، بنابراین این روش بر اساس پیوستگی کار می‌کند.
- (ج) GMM: خوشه‌ها بیضی‌شکل و کشیده هستند. GMM با ماتریس کوواریانس غیرقطری (full covariance) می‌تواند توزیع‌های بیضی‌شکل مایل را مدل کرده و این دو خوشه را جدا کند.
- چرا بقیه نه؟ k -means فرض می‌کند خوشه‌ها کروی هستند و نمی‌تواند ساختارهای کشیده و باریک را به درستی جدا کند.

تصویر D: پاسخ‌های ممکن: (ب)

- (ب) Single-link: این ساختار غیرمحدب (Non-convex) است. Single-link تنها الگوریتم در لیست است که بر اساس «نزدیک‌ترین همسایه» عمل کرده و می‌تواند شکل‌های کمانی یا تو در تو را دنبال کند.
- چرا بقیه نه؟ k -means و GMM (با $k = 2$) فرض می‌کنند خوشه‌ها محدب (کروی یا بیضی) هستند. هیچ بیضی یا دایره‌ای نمی‌تواند خوشه آبی (کمان داخلی) را بدون شامل شدن نقاط قرمز (کمان بیرونی) بپوشاند.

۶. (۱۵ نمره) می‌دانیم که نمایش‌های کم‌بعد برای مجموعه داده $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ در PCA به صورت زیر تعریف می‌شوند:

$$\mathbf{z}_i = \mathbf{U}^T (\mathbf{x}_i - \boldsymbol{\mu})$$

که در آن $\mathbf{U}$ ماتریسی است که سطرهای آن شامل k بردار ویژه بالایی ماتریس کوواریانس هستند و

$$\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

می‌باشد. نشان دهید که میانگین نمایش‌های کم‌بعد برابر صفر است:

$$\bar{\mathbf{z}} = \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i = \mathbf{0}$$

حل. برای اثبات اینکه $\bar{\mathbf{z}} = \mathbf{0}$ ، از تعریف میانگین روی بردارهای $\mathbf{z}_i$ شروع می‌کنیم و رابطه تبدیل PCA را در آن جایگذاری می‌کنیم:

$$\begin{aligned} \bar{\mathbf{z}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{U}^T (\mathbf{x}_i - \boldsymbol{\mu}) \end{aligned}$$

از آنجا که ماتریس $\mathbf{U}^\top$ مستقل از اندیس i است، می‌توانیم آن را از سیگما فاکتور بگیریم (خاصیت خطی بودن):

$$= \mathbf{U}^\top \left[\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}) \right]$$

سیگما را روی تفاضل پخش می‌کنیم:

$$= \mathbf{U}^\top \left[\left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \right) - \left(\frac{1}{n} \sum_{i=1}^n \boldsymbol{\mu} \right) \right]$$

با توجه به تعریف میانگین نمونه $\mathbf{x}_i = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$ و اینکه مجموع n عدد ثابت برابر با n ضرب در آن عدد است $(\sum_{i=1}^n \boldsymbol{\mu} = n\boldsymbol{\mu})$:

$$\begin{aligned} &= \mathbf{U}^\top \left[\boldsymbol{\mu} - \frac{1}{n} (n\boldsymbol{\mu}) \right] \\ &= \mathbf{U}^\top [\boldsymbol{\mu} - \boldsymbol{\mu}] \\ &= \mathbf{U}^\top \cdot \mathbf{0} \\ &= \mathbf{0} \end{aligned}$$

بنابراین ثابت شد که میانگین نمایش‌های کم‌بعد همواره برابر با بردار صفر است.