دانشگاه صنعتی شریف
دانشکده‌ی مهندسی کامپیوتر

یادگیری ماشین

پاییز و زمستان ۱۴۰۴

استاد: علی شریفی زارچی

گردآورندگان: گرامی‌راد - اعلایی - پیمایی - یگانگی دستگردی - دهقان‌پور

تمرین چهارم | بینایی کامپیوتر | مهلت ارسال: ۱۲ دی

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص‌شده است.
- در طول ترم، برای هر تمرین می‌توانید تا ۵ روز تأخیر مجاز داشته باشید و در مجموع حداکثر ۱۵ روز تأخیر مجاز خواهید داشت. توجه داشته باشید که تأخیر در تمرین‌های عملی و تئوری به صورت جداگانه محاسبه می‌شود و مجموع تأخیر هر دو نباید بیشتر از ۱۵ روز شود. پس از اتمام زمان مجاز، دو روز اضافی برای آپلود غیرمجاز در نظر گرفته شده است که در این بازه، به ازای هر ساعت تأخیر، ۲ درصد از نمره تمرین کسر خواهد شد.
- هم‌کاری و هم‌فکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتما باید توسط خود او نوشته شده باشد.
- در صورت هم‌فکری و یا استفاده از هر منابع خارج درسی، نام هم‌فکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفا تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.

سوالات نظری (۱۰۰ نمره)

۱. (۲۲ نمره) وقتی شبکه‌های عصبی بسیار عمیق می‌شوند، آموزش ممکن است به دلیل مشکل محو شدن گرادیان غیرممکن شود. ResNet این مسئله را با استفاده از skip connections حل می‌کند که به جریان بهتر گرادیان کمک می‌کنند.

محاسبات زیر را برای یک بلوک residual واحد در نظر بگیرید:

$$
\begin{aligned}
\mathbf{z}_1 &= \mathbf{W}_1\mathbf{x} + \mathbf{b}_1 \\
\mathbf{h}_1 &= \mathrm{ReLU}(\mathbf{z}_1) \\
\mathbf{d} &= \mathbf{h}_1 + \mathbf{x} \\
\mathbf{z}_2 &= \mathbf{W}_2\mathbf{d} + \mathbf{b}_2 \\
\mathbf{h}_2 &= \mathrm{ReLU}(\mathbf{z}_2) \\
\boldsymbol{\theta} &= \mathbf{h}_2 + \mathbf{d} \\
\hat{\mathbf{y}} &= \mathrm{softmax}(\boldsymbol{\theta}) \\
J &= \mathrm{CE}(\mathbf{y}, \hat{\mathbf{y}})
\end{aligned}
$$

فرض کنید $\mathbf{x}, \mathbf{d}, \boldsymbol{\theta} \in \mathbb{R}^{H\times 1}$ و $\mathbf{W}_1, \mathbf{W}_2 \in \mathbb{R}^{H\times H}$ باشند.

آ. $\boldsymbol{\delta}_\theta = \dfrac{\partial J}{\partial \boldsymbol{\theta}}$ و $\boldsymbol{\delta}_1 = \dfrac{\partial J}{\partial \mathbf{z}_1}$ را بیابید.

ب. $\boldsymbol{\delta}_2 = \dfrac{\partial J}{\partial \mathbf{z}_2}$ را بیابید.

پ. $\boldsymbol{\delta}_d = \dfrac{\partial J}{\partial \mathbf{d}}$ را محاسبه کنید.

ت. با استفاده از نتایج قبلی، $\dfrac{\partial J}{\partial \mathbf{x}}$ را محاسبه کنید.

۲. (۱۶ نمره)

یکی دیگر از مشکلاتی که در ارتباط با شبکه‌های ژرف وجود دارد، تعداد بالای پارامترها و پیچیدگی بالای محاسباتی است. این مشکل استفاده از شبکه‌های CNN روی دستگاه‌های کوچک با پردازنده‌های محدود (مانند تلفن همراه) را با دشواری‌هایی همراه می‌سازد. برای حل این مشکل، شبکه‌ی MobileNet ارائه شده است. شبکه‌ی MobileNet-V1 از کانولوشن عمقی (Depthwise) استفاده می‌کند که تعداد پارامترها و پیچیدگی زمانی را کاهش دهد.

آ. در شکل ۱ یک پیمانه از شبکه‌ی MobileNet-V1 (بالا) و یک لایه‌ی کانولوشن معمولی از شبکه‌ی CNN (پایین) نمایش داده شده است. در هر روش، تعداد پارامترها قابل آموزش را محاسبه کنید.

ب. در شبکه‌ی MobileNet-V2 از دو فیلتر کانولوشن ۱ × ۱ استفاده شده است. شمای کلی معماری استفاده‌شده از این شبکه در شکل ۲ نشان داده شده است. با محاسبه‌ی تعداد پارامترها برای این شبکه، آن را با MobileNet-V1 مقایسه نمایید.

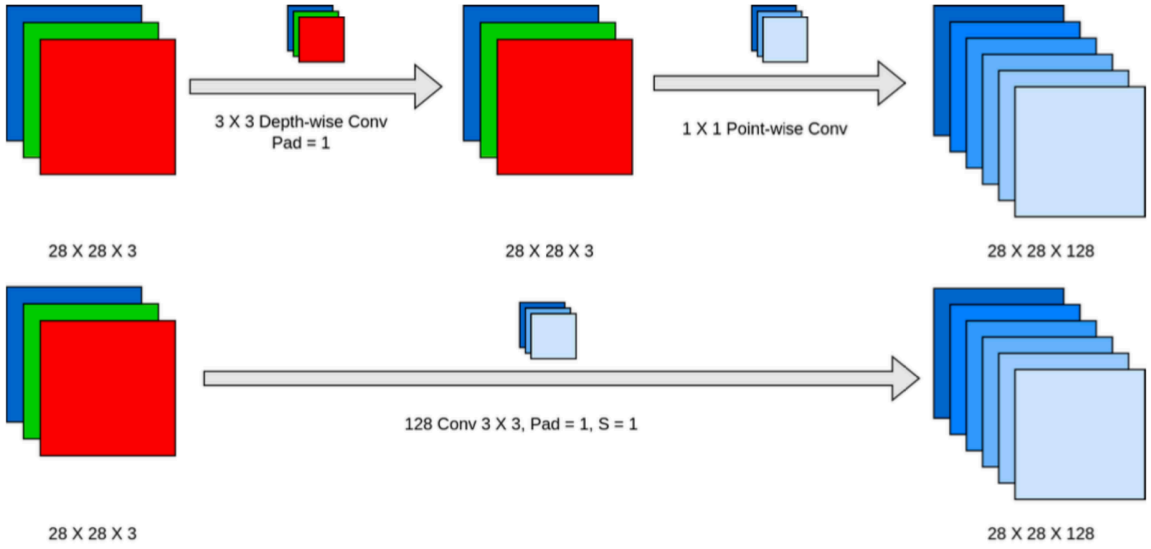

شکل ۱: یک پیمانه از شبکه‌ی MobileNet-V1 (بالا) و یک لایه‌ی کانولوشن معمولی (پایین).

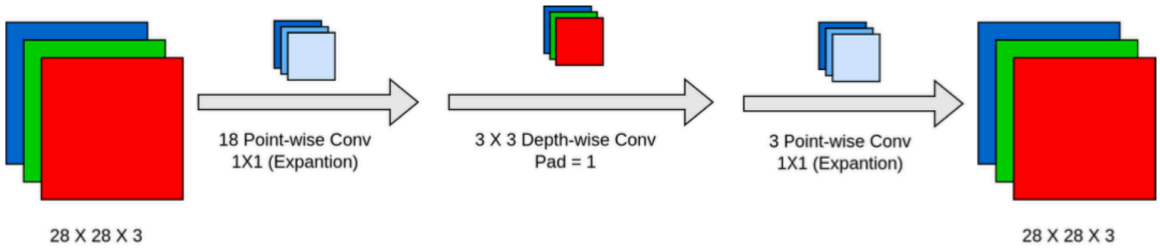

شکل ۲: شمای کلی بلوک MobileNet-V2 با استفاده از کانولوشن‌های ۱ × ۱ و کانولوشن عمقی ۳ × ۳.

۳. (۲۲ نمره) در بعضی از معماری‌های نوین کانولوشنی، به جای استفاده از لایه‌های تمام‌متصل[۱] در انتهای شبکه، از لایه ادغام میانگین سراسری[۲] استفاده می‌شود. فرض کنید خروجی آخرین لایه کانولوشن، یک تنسور $X \in \mathbb{R}^{C\times H\times W}$ باشد (که C تعداد کانال‌ها، و H, W ابعاد مکانی هستند).

آ. رابطه ریاضی برای محاسبه بردار خروجی y حاصل از ادغام میانگین سراسری را بنویسید. ابعاد بردار خروجی y چقدر است؟

ب. فرض کنید تنسور ویژگی ورودی دارای ابعاد ۷ × ۷ و تعداد کانال ۵۱۲ باشد ($H = W = ۷, C =$ ۵۱۲). می‌خواهیم این ویژگی‌ها را به یک لایه دسته‌بندی با ۱۰۰۰ کلاس متصل کنیم. تعداد پارامترهای قابل یادگیری (وزن‌ها) را در دو حالت زیر محاسبه و مقایسه کنید:

(آ) روش اول: صاف کردن[۳] تنسور و اتصال به یک لایه تمام‌متصل.

(ب) روش دوم: اعمال ادغام میانگین سراسری و سپس اتصال به یک لایه تمام‌متصل.

پ. توضیح دهید چرا استفاده از ادغام سراسری[۴] به شبکه اجازه می‌دهد تا تصاویر با ابعاد ورودی متغیر (مثلاً هم ۲۲۴ × ۲۲۴ و هم ۴۰۰ × ۴۰۰) را بپذیرد؟ چرا این امکان در روش صاف کردن ورودی وجود ندارد؟

ت. فرض کنید به جای میانگین، از ادغام بیشینه سراسری استفاده کنیم. اگر گرادیان لاس نسبت به خروجی این لایه برای کانال kـام برابر با δ_k باشد، گرادیان نسبت به پیکسل‌های ورودی $X_{k,i,j}$ در آن کانال چگونه توزیع می‌شود؟ (فرض کنید مقدار بیشینه یکتاست)

ث. فرض کنید ماتریس ورودی X با ابعاد ۳ × ۳ به صورت زیر داده شده است:

$$X = \begin{bmatrix} ۱ & ۳ & ۲ \\ ۴ & ۶ & ۵ \\ ۷ & ۸ & ۹ \end{bmatrix}$$

یک لایه ادغام بیشینه[۵] با ابعاد پنجره ۲ × ۲ و گام حرکت (Stride) برابر با ۱ روی این ورودی اعمال می‌شود.

ج. ماتریس خروجی Y را محاسبه کنید. (توجه کنید که به دلیل Stride=1، پنجره‌ها همپوشانی دارند).

چ. فرض کنید گرادیان تابع هزینه نسبت به خروجی این لایه ($\frac{\partial \mathcal{L}}{\partial Y}$) به صورت زیر به دست آمده باشد:

$$\frac{\partial \mathcal{L}}{\partial Y} = \begin{bmatrix} ۲ & -۳ \\ ۱ & ۴ \end{bmatrix}$$

ماتریس گرادیان نسبت به ورودی ($\frac{\partial \mathcal{L}}{\partial X}$) را محاسبه کنید.

راهنمایی: دقت کنید که برخی از پیکسل‌های ورودی ممکن است در محاسبه چندین خروجی مشارکت داشته باشند.

---

[۱] Fully Connected
[۲] Global Average Pooling (GAP)
[۳] Flatten
[۴] Global Pooling
[۵] Max Pooling

۴. (۲۲ نمره)

آ. فرض کنید یک تصویر $۳ \times ۳۲ \times ۳۲$ دارید.

- اگر این تصویر را با یک فیلتر $۳ \times ۵ \times ۵$، با استفاده از گام (stride) برابر ۱ و لایه‌گذاری (padding) برابر ۰ کانولوشن کنید، ابعاد مکانی حاصل چه خواهد بود؟
- اگر ورودی را به اندازه ۲ با صفر لایه‌گذاری (zero-pad) کنیم، ابعاد مکانی حاصل چه خواهد بود؟
- فرض کنید اکنون ۱۰ عدد از این فیلترهای $۳ \times ۵ \times ۵$ را روی هم قرار دهیم (با حفظ لایه‌گذاری ۲).
  - شکل جدید کامل خروجی چیست؟
  - چه تعداد پارامتر قابل یادگیری در این لایه وجود دارد (بدون در نظر گرفتن پارامترهای بایاس)؟
  - اگر بایاس را هم در نظر بگیریم، تعداد پارامترها چقدر خواهد بود؟
- ابعاد مکانی پس از اعمال یک کانولوشن ۱×۱ چه خواهد بود؟ توضیح دهید که این عملیات از نظر مفهومی چه کاری انجام می‌دهد.

ب. می‌دانیم کانولوشن‌ها عملیات خطی هستند و هر نگاشت خطی بین فضاهای با ابعاد محدود می‌تواند به صورت یک ماتریس بیان شود.
یک کانولوشن یک‌بعدی با ورودی $\mathbf{x} \in \mathbb{R}^۴$ و فیلتر $\mathbf{w} \in \mathbb{R}^۳$ را در نظر بگیرید. فرض کنید $\bar{\mathbf{x}}$ نشان‌دهنده نتیجه لایه‌گذاری صفر ورودی به اندازه ۱ در هر طرف باشد. ماتریس $\mathbf{W}$ را به گونه‌ای بسازید که:

$$\bar{\mathbf{x}} \star \mathbf{w} = \mathbf{W}\bar{\mathbf{x}}$$

راهنمایی: ابتدا عناصر بردار حاصل از کانولوشن را بنویسید.

پ. بیایید گرادیان‌ها را برای یک کانولوشن مشتق بگیریم. فرض کنید $\mathbf{y} = \mathbf{x} \star \mathbf{w} \in \mathbb{R}^۲$، که در آن $\mathbf{w} \in \mathbb{R}^۳$ و $\mathbf{x} \in \mathbb{R}^۴$ (بدون لایه‌گذاری صفر) است. فرض کنید L تابع زیان (loss function) باشد و $\nabla_{\mathbf{y}} L$ گرادیان زیان نسبت به خروجی کانولوشن را نشان دهد.

- گرادیان L نسبت به ورودی $\mathbf{x}$ را محاسبه کنید (یعنی $\frac{\partial L}{\partial \mathbf{x}}$). آیا می‌توانید این گرادیان را به صورت یک کانولوشن بیان کنید؟
- گرادیان L نسبت به وزن‌های $\mathbf{w}$ را محاسبه کنید (یعنی $\frac{\partial L}{\partial \mathbf{w}}$). آیا می‌توانید این گرادیان را به صورت یک کانولوشن بیان کنید؟

۵. (۱۸ نمره) یکی از تصمیمات مهم در طراحی معماری‌های کانولوشنی، انتخاب اندازه هسته [۶] و عمق شبکه است که مستقیماً بر میدان دید[۷] و تعداد پارامترها تاثیر می‌گذارد.

آ. فرض کنید ورودی یک تنسور با تعداد کانال C باشد. دو معماری زیر را در نظر بگیرید:
«الف»: استفاده از یک لایه کانولوشن با سایز هسته ۵ × ۵.
«ب»: استفاده از دو لایه متوالی کانولوشن با سایز هسته ۳ × ۳.
(فرض کنید در هر دو حالت Stride=1 است و تعداد کانال‌های ورودی و خروجی در تمام لایه‌ها برابر C می‌باشد).

(آ) نشان دهید که میدان دید نهایی در هر دو معماری یکسان است.

(ب) تعداد پارامترهای این دو معماری را محاسبه کرده (از تعداد پارامترهای بایاس صرف نظر کنید). کدام معماری پارامتر کمتری دارد؟

(ج) جدا از بحث تعداد پارامتر، مزیت اصلی «معماری ب» (لایه‌های متوالی کوچک) نسبت به «معماری الف» از نظر سوگیری القایی [۸] و یادگیری ویژگی‌های غیرخطی چیست؟

ب. سوگیری القایی در شبکه‌های کانولوشنی معمولاً با دو ویژگی محلی بودن و هم‌ارزی انتقالی [۹] شناخته می‌شود. رابطه ریاضی عملگر کانولوشن برای ورودی x و فیلتر w به صورت $y(t) = (x * w)(t)$ تعریف می‌شود. اگر عملگر شیفت (انتقال) ورودی به اندازه h واحد را با T_h نشان دهیم (یعنی $(T_h x)(t) = x(t-h)$):
ثابت کنید که عملگر کانولوشن نسبت به انتقال هم‌ارز است. یعنی نشان دهید:

$$(T_h x) * w = T_h(x * w)$$

پ. در بسیاری از شبکه‌های مدرن، با جلو رفتن در لایه‌ها، رزلوشن مکانی ($H \times W$) کاهش و تعداد کانال‌ها (C) افزایش می‌یابد. توضیح دهید این طراحی چگونه باعث تغییر نوع ویژگی‌های یاد گرفته شده می‌شود و چه ارتباطی با افزایش میدان دید دارد؟

---

[۶] Kernel Size
[۷] Receptive Field
[۸] Inductive Bias
[۹] Translation Equivariance