



دانشگاه صنعتی شریف

دانشکده‌ی مهندسی کامپیووتر

## یادگیری ماشین

پاییز و زمستان ۱۴۰۴

استاد: علی شریفی زارچی

گردآورندگان:

مهلت ارسال:

### یادگیری با نظارت

حل تمرین ۱

۱. (نمره) مسئله‌ای داریم که در آن داده‌های واقعی از تابع  $f(x)$  تولید می‌شوند. با استفاده از مجموعه‌ی داده‌های یادگیری  $\mathcal{D}$ ، که مقادیر آن از همان تابع  $f$  پیروی می‌کنند، مدل  $(x)g^{(\mathcal{D})}$  را آموزش می‌دهیم. در این صورت خطای مورد انتظار برای داده‌های خارج از نمونه از رابطه‌ی زیر بدست می‌آید:

$$E_{\text{out}}(g^{(\mathcal{D})}) = \mathbb{E}_x [(f(x) - g^{(\mathcal{D})}(x))^2]$$

در واقع در این رابطه، مقدار میانگین خطای داده‌های خارج را با استفاده از اختلاف  $(x)g^{(\mathcal{D})}$  با تابع مولد داده‌ها محاسبه می‌کنیم. این مقدار به ما در بررسی عملکرد مدل کمک می‌کند و کم بودن آن بیانگر قابلیت مدل در تعیین بر روی داده‌های دیده نشده است، و در صورتی که مقدار آن زیاد باشد نتیجه می‌گیریم که مدل عملکرد مناسبی بر روی داده‌های دیده نشده ندارد. اگر میانگین این عبارت را نسبت به همه‌ی  $\mathcal{D}$ ‌های محاسبه کنیم، خواهیم داشت:

$$\mathbb{E}_{\mathcal{D}} E_{\text{out}}(g^{(\mathcal{D})}) = \text{bias}^2 + \text{var}$$

در این صورت بدون در نظر گرفتن هیچ  $\mathcal{D}$  خاص می‌توانیم عملکرد مدل را مورد بررسی قرار دهیم. حال اگر در داده‌هایمان نویز داشته باشیم، یعنی بجای دسترسی به داده‌هایی که از تابع  $f$  آمده‌اند، به داده‌هایی دسترسی داشته باشیم که از تابع  $y(x) = f(x) + \varepsilon$  می‌توانیم بگوییم:

$$E_{\text{out}}(g^{(\mathcal{D})}) = \mathbb{E}_{x,y} [(y(x) - g^{(\mathcal{D})}(x))^2]$$

در واقع در این حالت فرض می‌کنیم که مانند قبل تابع  $f(x)$  ای وجود دارد که به دنبال یافتن آن هستیم، اما هنگام تولید داده‌ها، مقداری نویز وجود داشته که مقادیر خروج را از مقادیر واقعی آنها متفاوت کرده است و در نتیجه داده‌های خروج به شکل  $y(x) = f(x) + \varepsilon$  هستند و نه  $y(x)$ . در چنین شرایطی، به دنبال یافتن تابعی هستیم که همچنان خود  $f(x)$  (و نه  $y(x)$ ) را به میزان خوبی تخمین بزند. متغیر تصادفی  $\varepsilon$ ، همان نویز بوده و میانگین و واریانس آن را در این مثال به ترتیب صفر و  $\sigma^2$  در نظر می‌گیریم. با توجه به توضیحات و فرض داده شده، نشان دهید:

$$\mathbb{E}_{\mathcal{D}} E_{\text{out}}(g^{(\mathcal{D})}) = \text{bias}^2 + \text{var} + \sigma^2$$

۲. (نمره) فرض کنید در مسئله‌ی رگرسیون مقداری نویز به صورت زیر داشته باشیم:

$$X \in \mathbb{R}^{n \times d}, \quad w \in \mathbb{R}^d, \quad y \in \mathbb{R}^n, \quad \varepsilon \sim \mathcal{N}(0, I_n)$$

$$y + \varepsilon = Xw$$

برای سادگی مقدار  $\tilde{y} \in \mathbb{R}^n$  را به صورت  $\tilde{y} = y + \varepsilon$  تعریف می‌کنیم. داده‌های ما به گونه‌ای باشند که برای مقادیر بدون نویز  $y$  رابطه‌ی  $y = Xw$  برقرار است. اکنون با فرض اینکه تنها مقادیر  $X$  و  $\tilde{y}$  برای آموزش مدل در دسترس باشند، به پرسش‌های زیر پاسخ دهید.

- آ. پاسخ مدل را برای نقطه‌ی فرض  $z \in \mathbb{R}^d$  با  $\tilde{f}(z) = \tilde{y}(z)$  نمایش می‌دهیم. عبارت  $(\tilde{f}(z))$  بر حسب  $z$  چیست؟  
ب. می‌خواهیم امید ریاضی خطای مدل یعنی  $\mathbb{E}[(\tilde{y}(z) - \tilde{f}(z))^2]$  محاسبه کنیم. تجزیه‌ی بایاس-واریانس این عبارت را انجام دهید و مشخص کنید هر کدام از بخش‌های بدست آمده نشان‌دهنده‌ی چه چیزی هستند.

پ. بایاس مدل را محاسبه کنید.

ت. نشان دهید که واریانس مدل برابر با  $z^\top (X^\top X)^{-1} z$  می‌باشد.

ث. چرا در اینجا برای هر نقطه‌ی تست دلخواه مثل  $z$  واریانس حداقل برابر با بایاس می‌باشد؟

۳. (نمره) دو عضو  $\mathbb{R}^2$  را درنظر بگیرید.

۱. نشان دهید فضای ویژگی‌ای که کرنل  $k_1(a, b) = (a^\top b)^2$  را تعریف می‌کند به شکل زیر است:

$$\phi([x_1, x_2]^\top) = \begin{pmatrix} x_1 \\ \sqrt{2}x_1x_2 \\ x_2 \end{pmatrix}$$

۲. نشان دهید فضای ویژگی‌ای که کرنل  $k_2(a, b) = (1 + a^\top b)^2$  را تعریف می‌کند به شکل زیر است:

$$\phi([x_1, x_2]^\top) = \begin{pmatrix} x_1 \\ \sqrt{2}x_1x_2 \\ x_2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \\ 1 \end{pmatrix}$$

۴. (نمره) فرض کنید مجموعه‌داده‌ای به شکل

$$\{(1, 0), (\theta, 1), (-1, 0)\}$$

برای مسئله‌ی رگرسیون در اختیار داریم که  $\cdot \leq \theta$ .

دو مدل

$$h_1(x) = b$$

و

$$h_2(x) = ax + b$$

را در نظر بگیرید. میزان خطای LOOCV را با استفاده از معیار خطای میانگین مربعات خطای برای هر کدام از این دو مدل محاسبه نمایید و مشخص کنید که به ازای چه مقداری از  $\theta$  میزان خطای دو مدل ارائه شده برابر می‌شود.

۵. (نمره) قانون بهروزرسانی بردار وزن در پرسپترون را در نظر بگیرید:

if  $x^{(t)}$  is misclassified then:

$$\omega^{(t+1)} = \omega^{(t)} + \eta y^{(t)} x^{(t)}$$

نشان دهید که در دسته‌بند پرسپترون، بردار وزن  $w$  را می‌توان به صورت ترکیب خطی داده‌ها نوشت:

$$w = \sum_{i=1}^N \alpha_i x_i$$

ضرایب  $\alpha_i$  را در این ترکیب خطی مشخص کنید.